



PROGETTO MACHINE LEARNING

INDICE

Il progetto ha previsto la creazione di un albero decisionale sfruttando i dati contenuti in un *file csv*, sfruttando solo le colonne di interesse per creare un modello predittivo.

Lo svolgimento del progetto è riassumibile in 7 punti:

- Importazione delle librerie e creazione di un dataframe dal csv.
- Visualizzazione/Analisi/Pulizia dei dati.
- Feature Engineering.
- Divisione del set in train/test/convalida.
- Ottimizzazione del Modello.
- Creazione del Modello Finale.
- Valutazione/Visualizzazione del Modello.



LIBRERIE E DATAFRAME

- Import le librerie e creo un dataframe denominato df.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
from sklearn.preprocessing import LabelEncoder
from sklearn.tree import plot_tree
import matplotlib.pyplot as plt

# Leggo il csv creando un dataframe df
df = pd.read_csv('titanic_sub.csv')
```

VISUALIZZAZIONE/ANALISI/PULIZIA DEI DATI

- Visualizzo il contenuto del df precedentemente creato, successivamente converto i nomi delle colonne in minuscolo.

```
# Dò un primo sguardo alle prime righe del df  
df.head()
```

	PassengerId	Sex	Age	Pclass	Embarked	Survived
0	1	male	22.0	3	S	0
1	2	female	38.0	1	C	1
2	3	female	26.0	3	S	1
3	4	female	35.0	1	S	1
4	5	male	35.0	3	S	0

```
# Convertire tutti i nomi delle colonne in minuscolo  
df.columns = df.columns.str.lower()  
df.columns
```

```
Index(['passengerid', 'sex', 'age', 'pclass', 'embarked', 'survived'], dtype='object')
```

VISUALIZZAZIONE/ANALISI/PULIZIA DEI DATI

- Controllo se sono presenti valori duplicati, sia prima che dopo aver impostato la colonna 'passengerid' come indice, qualora ci fossero ne elimino i casi.

```
# Controllo che non ci siano casi duplicati ritornando il numero totale di righe duplicate
df.duplicated().sum()

# Se ci fossero stati dei duplicati sarebbero stati tolti con
#df = df.drop_duplicates(ignore_index=True)
✓ 0.0s
0
```

```
# Imposta la colonna 'passengerid' come indice
df = df.set_index('passengerid')
# Dò un sguardo alla modifica apportata
df.head()
✓ 0.0s
```

	sex	age	pclass	embarked	survived
passengerid					
1	male	22.0	3	S	0
2	female	38.0	1	C	1
3	female	26.0	3	S	1
4	female	35.0	1	S	1
5	male	35.0	3	S	0

```
# Controllo che non ci siano casi duplicati ritornando il numero totale di righe duplicate
df.index.duplicated().sum()
# Se ci fossero stati dei duplicati, avrei lavorato sugli indici e sarebbero stati tolti con
#df.drop(df.index[df.index.duplicated(keep='first')])
✓ 0.0s
0
```

VISUALIZZAZIONE/ANALISI/PULIZIA DEI DATI

- Analizzo più approfonditamente la struttura dei dati contenuta nel df.

```
# Analizzo le varie informazioni del df  
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 891 entries, 0 to 890  
Data columns (total 6 columns):  
#   Column      Non-Null Count  Dtype  
---  ---  
0   passengerid  891 non-null    int64  
1   sex          891 non-null    object  
2   age          714 non-null    float64  
3   pclass       891 non-null    int64  
4   embarked     889 non-null    object  
5   survived     891 non-null    int64  
dtypes: float64(1), int64(3), object(2)  
memory usage: 41.9+ KB
```

VISUALIZZAZIONE/ANALISI/PULIZIA DEI DATI

- Controllo se sono presenti valori NAN, in questo caso li sostituisco con il valore mediano.

```
# Controllo che per ogni colonna se ci sono e la quantità di valori nan  
df.isnull().sum()
```

```
passengerid    0  
sex            0  
age          177  
pclass         0  
embarked       2  
survived       0  
dtype: int64
```

```
# Sostituisco i valori nan nella colonna 'age' con la rispettiva mediana  
df['age'] = df['age'].fillna(df['age'].median())
```

✓ 0.0s

```
# Controllo che per ogni colonna se ci sono e la quantità di valori nan  
df.isnull().sum()
```

✓ 0.0s

```
sex            0  
age            0  
pclass         0  
embarked       2  
survived       0  
dtype: int64
```

FEATURE ENGINEERING

- Creo 1 colonna binarie utilizzando `get_dummies()` derivate dalla colonna 'sex', denominata 'sex_male' così da avere delle colonne One-Hot.

```
# Creare la colonna 'sex_male' One-Hot per 'sex' usando get_dummies, e modificare direttamente nel DataFrame originale
df['sex_male'] = pd.get_dummies(df['sex'], prefix='', drop_first=True)
# Mostro il df con modifiche
df.head()
```

✓ 0.0s

	sex	age	pclass	embarked	survived	sex_male
passengerid						
1	male	22.0	3	S	0	True
2	female	38.0	1	C	1	False
3	female	26.0	3	S	1	False
4	female	35.0	1	S	1	False
5	male	35.0	3	S	0	True

FEATURE ENGINEERING

- Creo 3 colonne utilizzando `get_dummies()` derivate dalla colonna 'embarked', così da avere colonne One-Hot evitando correlazioni intrinseche tra i valori, come farebbe la funzione `LabelEncoder()`.

```
# Creare le colonne One-Hot per 'embarked' usando get_dummies e aggiungerle direttamente al DataFrame
df_dummies = pd.get_dummies(df['embarked'], prefix='', prefix_sep='')

# Rendi i nomi delle colonne in minuscolo
df_dummies.columns = df_dummies.columns.str.lower()

# Aggiungi direttamente al DataFrame originale
df[df_dummies.columns] = df_dummies
# Mostro il df con modifiche
df.head()
```

✓ 0.0s

	sex	age	pclass	embarked	survived	sex_male	c	q	s
passengerid									
1	male	22.0	3	S	0	True	False	False	True
2	female	38.0	1	C	1	False	True	False	False
3	female	26.0	3	S	1	False	False	False	True
4	female	35.0	1	S	1	False	False	False	True
5	male	35.0	3	S	0	True	False	False	True

DIVISIONE DEL SET IN TRAIN/TEST/CONVALIDA

- Uso `.seed(0)` per garantire la riproducibilità, divido le colonne in features e target, divido il df in 3 set, train, test, convalida con i rispettivi valori target.

```
# Impostare il seed per la riproducibilità
np.random.seed(0)

# Selezioniamo le feature (variabili predittive) e il target (variabile da prevedere)
features = df[['age', 'pclass', 'c', 'q', 's', 'sex_male']] # Le colonne scelte come variabili indipendenti
target = df['survived'] # La colonna 'survived' è il target

# Divido le feature dal target per creare X (features) e y (target)
X = features
y = target # Target (classe), che in questo caso è la sopravvivenza

# Suddividere i dati in set di addestramento (75%) e di test (25%)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=78) # 78 + mediana

# Creazione del set di validazione (25%) dal set di train precedente
X_train, X_val, y_train, y_val = train_test_split(X_train, y_train, test_size=0.25, random_state=78) # 78 + median
```

OTTIMIZZAZIONE DEL MODELLO

- Creo diversi modelli testando varie profondità, catturando quello più performante.

```
# Variabili per confronto
best_depth = None # Inizializza la variabile per la miglior profondità
best_score = 0 # Inizializza il punteggio di validazione più basso
best_model = 0 # Inizializza il miglior modello (indicato come 0 per ora)

# Ciclo per testare diverse profondità dell'albero decisionale
for depth in [2, 5, 10, 25]:
    # Creare un modello di Albero Decisionale con la profondità attuale
    model = DecisionTreeClassifier(max_depth=depth) # Crea il modello con la profondità attuale

    # Addestrare il modello sui dati di addestramento
    model.fit(X_train, y_train) # Adatta il modello ai dati di addestramento (X_train, y_train)

    # Calcoliamo la performance sul set di validazione
    valid_score = model.score(X_val, y_val) # Calcola la precisione sul set di validazione (X_val, y_val)
    print(f"Profondità: {depth}, Performance sulla validazione: {valid_score}") # Stampa il risultato

    # Se la performance è migliore, salviamo questa profondità
    if valid_score > best_score: # Confronta se il punteggio di validazione è migliore di quello precedente
        best_score = valid_score # Aggiorna il miglior punteggio
        best_depth = depth # Salva la profondità migliore
        best_model = model # Salva il miglior modello

# Stampa la profondità migliore trovata e il suo punteggio di validazione
print(f"\nLa miglior profondità per il modello è: {best_depth} con un punteggio di validazione di: {best_score}") # Risultato finale
```

```
Profondità: 2, Performance sulla validazione: 0.7664670658682635
Profondità: 5, Performance sulla validazione: 0.7964071856287425
Profondità: 10, Performance sulla validazione: 0.7844311377245509
Profondità: 25, Performance sulla validazione: 0.7964071856287425
```

```
La miglior profondità per il modello è: 5 con un punteggio di validazione di: 0.7964071856287425
```

CREAZIONE DEL MODELLO FINALE

- Creo e testo il miglior modello con il set di test.

```
# Addestrare il miglior modello sui dati di addestramento  
best_model.fit(X_train, y_train) # Riaddestra il miglior modello sui dati di addestramento  
  
# Fare delle previsioni sui dati di test  
y_pred = best_model.predict(X_test) # Fai delle previsioni sui dati di test  
  
# Calcolare L'accuratezza  
accuracy = accuracy_score(y_test, y_pred) # Calcola L'accuratezza confrontando le previsioni con il target  
print(f"Accuracy: {accuracy} \n") # Stampa L'accuratezza
```

- Valuto la percentuale di accuratezza.

```
Accuracy: 0.8609865470852018
```

VALUTAZIONE/VISUALIZZAZIONE DEL MODELLO

- Creo e visualizzo la confusion matrix ed il classification report.

```
# Matrice di confusione
print("Confusion Matrix:") # Stampa "Confusion Matrix:"
print(confusion_matrix(y_test, y_pred), '\n') # Calcola e stampa la matrice di confusione
```

La **confusion matrix** è una matrice 2x2 (per classificazione binaria) o più grande (per classificazione multiclasse) che mostra come il modello ha classificato correttamente o erroneamente le istanze. Le celle principali della matrice sono:

- **True Positives (TP)**: i casi correttamente classificati come positivi. (In lato a sinistra)
- **True Negatives (TN)**: i casi correttamente classificati come negativi. (in basso a destra)
- **False Positives (FP)**: i casi erroneamente classificati come positivi. (in alto a destra)
- **False Negatives (FN)**: i casi erroneamente classificati come negativi. (in basso a sinistra)

Questa matrice è utile per capire non solo la correttezza complessiva del modello, ma anche i tipi di errori che fa.

```
Confusion Matrix:
[[134   9]
 [ 22  58]]
```

VALUTAZIONE/VISUALIZZAZIONE DEL MODELLO

- Creo e visualizzo la confusion matrix ed il classification report.

```
# Report di classificazione (precision, recall, f1-score)
print("Classification Report:") # Stampa "Classification Report:"
print(classification_report(y_test, y_pred)) # Calcola e stampa il report di classificazione (precisione, recall, F1-score)
```

Il **classification report** è una sintesi che include diverse metriche utili per valutare le prestazioni di un modello di classificazione. Le principali sono:

- **Precision**: la frazione di predizioni positive corrette ($TP / (TP + FP)$).
- **Recall**: la frazione di veri positivi che sono stati correttamente identificati ($TP / (TP + FN)$).
- **F1-score**: la media armonica tra precision e recall, che bilancia entrambi ($2 * (Precision * Recall) / (Precision + Recall)$).
- **Support**: il numero di occorrenze per ciascuna classe nel dataset.

Insieme, la confusion matrix e il classification report forniscono un'analisi completa delle prestazioni di un modello di classificazione.

```
Classification Report:
              precision    recall  f1-score   support


     0       0.86      0.94      0.90       143
     1       0.87      0.72      0.79        80

 accuracy          0.86          0.86          0.86       223
 macro avg       0.86      0.83      0.84       223
 weighted avg    0.86      0.86      0.86       223
```

VALUTAZIONE/VISUALIZZAZIONE DEL MODELLO

- Creo una visualizzazione grafica dell'albero decisionale (immagine completa nel Drive).

```
# Visualizzare l'albero decisionale
plt.figure(figsize=(100, 50)) # Imposta la dimensione della figura per il grafico
plot_tree(best_model, filled=True, feature_names=features.columns, class_names=features.columns) # Disegna l'albero decisionale
plt.show() # Mostra il grafico
```



CONSIDERAZIONI FINALI

In conclusione, questo progetto è finalizzato a fare pratica con un modello ad albero decisionale di classificazione, sfruttando i dati contenuti in un *file csv* per prevedere un output di 0 o 1 dato un input di diverse feature, è stato interessante creare e capire le potenzialità di questo tipo di modello.



LINK PROGETTO

All'interno di questo Drive è disponibile il file csv, la visualizzazione dell'albero ed il notebook .ipynb:

[progetto mli - Google Drive](#)



This work is licensed under a Creative Commons Attribution 4.0 International License.

