PROGETTO QUERY SQL

INDICE

Il progetto ha previsto la creazione di *query SQL* sfruttando i dati contenuti in *file csv*, estraendone dati di interesse e determinandone correlazioni.

Lo svolgimento del progetto è riassumibile in 6 punti:

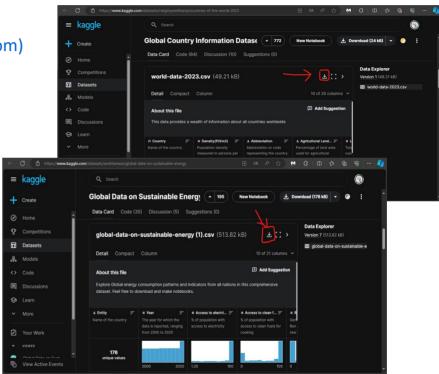
- Recupero dei dati
- Analisi dei dati
- Pulizia dei dati
- Importazione dei dati
- Realizzazione delle query
- Considerazioni finali



RECUPERO DEI DATI

- Download dei due file csv da:
 - Global Country Information Dataset 2023 (kaggle.com)
 - Global Data on Sustainable Energy (2000-2020) (kaggle.com)

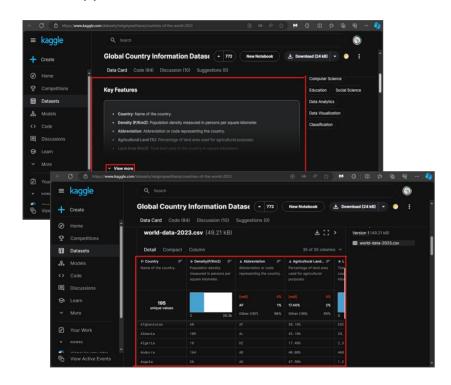


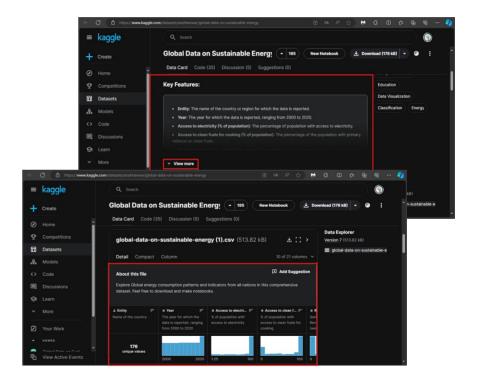




ANALISI DEI DATI

• Studio approfondito dei dati contenuti nei file csv dal sito di download.

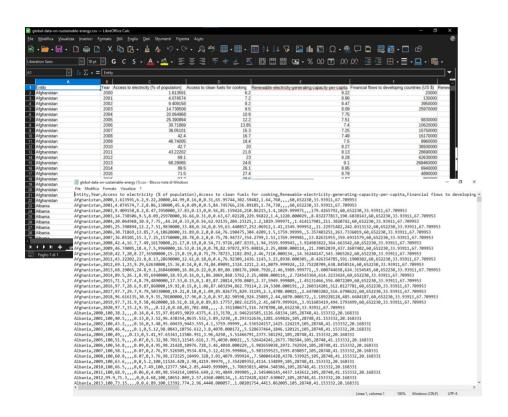


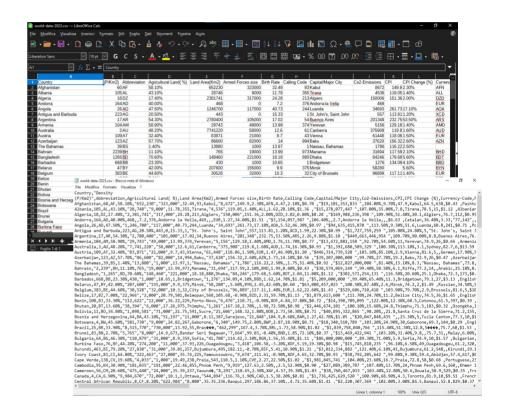




ANALISI DEI DATI

• Analisi più accurata dei dati contenuti nei file csv per stabilire il tipo di dato tramite lettura da file txt e LibreOffice.







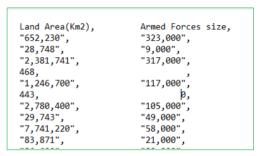
PULIZIA DEI DATI

• La pulizia dei dati ha previsto la modifica delle informazioni contenute nelle colonne da "stringa" ad "intero" o "numeric", la modifica della formattazione attraverso la sostituzione della virgola "," con il punto "." e conseguentemente il punto "." con uno spazio " ". Infine è stata effettuata l'eliminazione dei caratteri superflui "%" e "\$".

Forested Area (%)	Gasoline Price	GDP	Gross primary education enrollment (%)
2.10%	\$0.70	\$19,101,353,833	104.00%
28.10%	\$1.36	\$15,278,077,447	107.00%
0.80%	\$0.28	\$169,988,236,398	109.90%
34.00%	\$1.51	\$3,154,057,987	106.40%
46.30%	\$0.97	\$94,635,415,870	113.50%
22.30%	\$0.99	\$1,727,759,259	105.00%
9.80%	\$1.10	\$449,663,446,954	109.70%
11.70%	\$0.77	\$13,672,802,158	92.70%
40.000/	40.00	A4 000 000 F00 000	400.000/



Forested Area (%)	Gasoline Price	GDP	Gross primary education enrollment (%)
2.1	0.7	19101353833	104
28.1	1.36	15278077447	107
0.8	0.28	169988236398	109.9
34	1.51	3154057987	106.4
46.3	0.97	94635415870	113.5
22.3	0.99	1727759259	105
9.8	1.1	449663446954	109.7
11.7	0.77	13672802158	92.7
16.3	0.93	1392680589329	100.3





Land Area(Km2),	Armed Forces size,	
652230,	323000,	
28748,	9000,	
2381741,	317000,	
468,	0,	
1246700,	117000,	
443,	0,	
2780400,	105000,	
29743,	49000,	
7741220,	58000,	
83871,	21000,	



IMPORTAZIONE DEI DATI

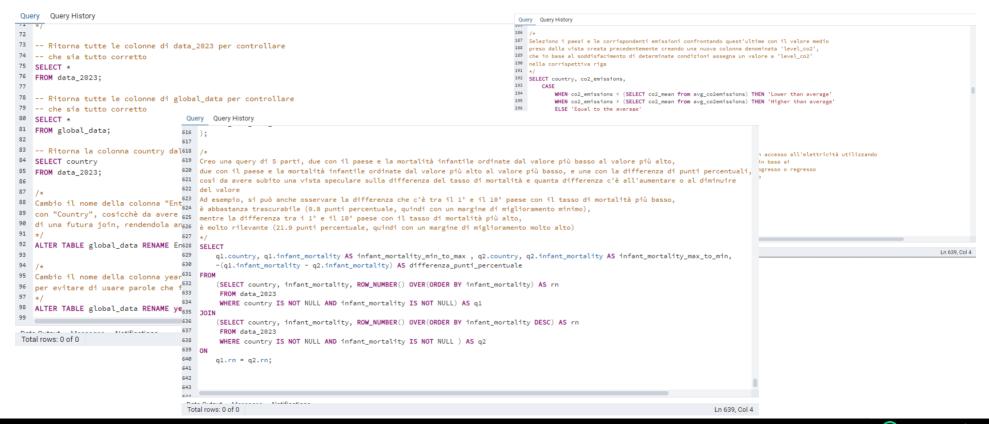
• L'importazione dei dati è stata eseguita in *PgAdmin 4* dopo aver creato gli schemi delle tabelle specificando i tipi di dati delle colonne.

```
Query Query History
       SCHEMA CREAZIONE TABELLA data_2023
       CREATE TABLE data 2023(
       Country VARCHAR(255),
       Density INTEGER,
       Abbreviation VARCHAR(255).
       Agricultural_Land NUMERIC,
      Land Area NUMERIC.
      Armed_Forces_size INTEGER.
       Birth_Rate NUMERIC,
       Calling_Code INTEGER.
       Capital_Major_City VARCHAR(255),
       Co2_Emissions INTEGER,
       CPI NUMERIC.
       CPI_Change NUMERIC,
       Currency_Code VARCHAR(255),
       Fertility_Rate NUMERIC
       Forested Area NUMERIC.
       Gasoline_Price NUMERIC.
       GDP BIGINT.
       Gross_primary_education_enrollment NUMERIC,
       Gross tertiarveducation enrollment NUMERIC.
       Infant mortality NUMERIC.
       Largest_city VARCHAR(255),
       Life_expectancy NUMERIC,
       Maternal mortality ratio INTEGER.
       Minimum_wage NUMERIC.
       Official_language VARCHAR(255),
       Out_of_pocket_health_expenditure NUMERIC,
       Physicians_per_thousand NUMERIC,
       Population INTEGER,
       Population_Labor_force_participation NUMERIC.
       Tax_revenue NUMERIC.
       Total_tax_rate NUMERIC
       Unemployment_rate NUMERIC,
       Urban_population INTEGER,
       Latitude NUMERIC.
       Longitude NUMERIC
42 */
43
44 /*
 Data Output Messages Notifications
 Total rows: 0 of 0
```

```
Ouerv
       Ouery History
44 /*
        SCHEMA CREAZIONE TABELLA global_data
47
        CREATE TABLE global_data(
        Entity VARCHAR(255),
50
        Year INTEGER,
51
        Access_to_electricity NUMERIC,
52
        Access to clean fuels for cooking NUMERIC,
53
        Renewable electricity generating capacity per capita NUMERIC,
54
        Financial_flows_to_developing_countries_BIGINT,
55
        Renewable_energy_share_in_the_total_final_energy_consumption NUMERIC,
56
       Electricity_from_fossil_fuels NUMERIC,
57
       Electricity_from_nuclear NUMERIC,
58
       Electricity_from_renewables NUMERIC,
59
       Low_carbon_electricity NUMERIC,
        Primary_energy_consumption_per_capita NUMERIC,
        Energy_intensity_level_of_primary_energy NUMERIC,
        Value_co2_emissions_kt_by_country NUMERIC,
        Renewables NUMERIC,
        gdp_growth NUMERIC,
        gdp_per_capita NUMERIC,
        Density INTEGER,
67
       Land Area INTEGER,
       Latitude NUMERIC.
       Longitude NUMERIC
70 );
71 */
```

REALIZZAZIONE DELLE QUERY

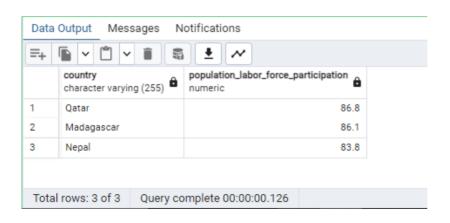
Inizio del progetto vero e proprio sulla creazione di varie query.

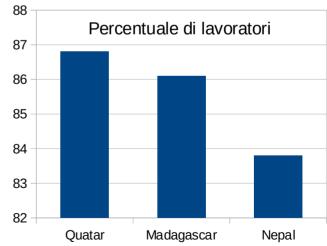


Lo scopo della query 1 è quello di estrarre i 3 paesi con il tasso di lavoratori più alto.

```
SELECT country, population_labor_force_participation
FROM data_2023
WHERE population_labor_force_participation IS NOT NULL
ORDER BY population_labor_force_participation DESC
LIMIT 3;
```

Risultato:

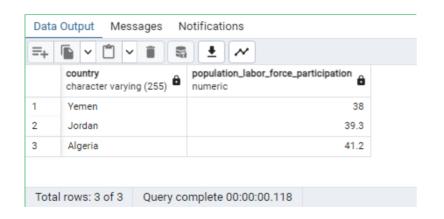




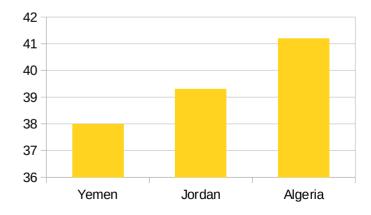
La query 2 è stata creata per estrarre i 3 paesi con il tasso di lavoratori più basso.

```
SELECT country, population_labor_force_participation
FROM data_2023
WHERE population_labor_force_participation IS NOT NULL
ORDER BY population_labor_force_participation
LIMIT 3;
```

Risultato:



Percentuale di lavoratori



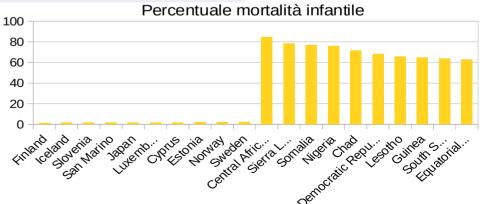
Per avere una visione dei dati più ampia, è stata creata la query 3, composta da 5 parti: due con il paese e la mortalità infantile, ordinate dal valore più basso al valore più alto, due con il paese e la mortalità infantile, ordinate dal valore più alto al valore più basso, e una con la differenza di punti percentuali, al fine di avere un confronto a specchio sulla differenza del tasso di mortalità fra i primi e gli ultimi valori.

```
628 SELECT
629
        q1.country, q1.infant mortality AS infant mortality min to max , q2.country, q2.infant mortality AS infant mortality max to min,
630
        -(q1.infant mortality - q2.infant mortality) AS differenza punti percentuale
    FROM
631
632
        (SELECT country, infant_mortality, ROW_NUMBER() OVER(ORDER BY infant_mortality) AS rn
633
         FROM data 2023
         WHERE country IS NOT NULL AND infant_mortality IS NOT NULL) AS q1
634
635
    JOIN
636
        (SELECT country, infant_mortality, ROW_NUMBER() OVER(ORDER BY infant_mortality DESC) AS rn
637
         FROM data 2023
         WHERE country IS NOT NULL AND infant mortality IS NOT NULL ) AS q2
638
639
        q1.rn = q2.rn;
641
```

Risultato:

Data	Data Output Messages Notifications							
	country character varying (255)	infant_mortality_min_to_max numeric	country character varying (255)	infant_mortality_max_to_min numeric	differenza_punti_percentuale numeric			
1	Finland	1.4	Central African Republic	84.5	83.1			
2	Iceland	1.5	Sierra Leone	78.5	77.0			
3	Slovenia	1.7	Somalia	76.6	74.9			
4	San Marino	1.7	Nigeria	75.7	74.0			
5	Japan	1.8	Chad	71.4	69.6			
6	Luxembourg	1.9	Democratic Republic of the Con	68.2	66.3			
7	Cyprus	1.9	Lesotho	65.7	63.8			
8	Estonia	2.1	Guinea	64.9	62.8			
9	Norway	2.1	South Sudan	63.7	61.6			
10	Sweden	2.2	Equatorial Guinea	62.6	60.4			
Total rows: 188 of 188								

• Ad esempio, è possibile osservare che la differenza tra il 1° e il 10° paese con il tasso di mortalità più basso è abbastanza trascurabile (0.8 punti percentuale, quindi con un margine di miglioramento minimo), mentre la differenza tra i 1° e il 10° paese con il tasso di mortalità più alto è molto rilevante (21.9 punti percentuale, quindi con un margine di miglioramento molto alto).





Alberto Bracci

La query 4 è composta da più query.
 La prima ha richiesto la creazione di una vista "correlation" che ritorna il paese, l'area forestale, le emissioni di CO₂ e la correlazione di Pearson, derivante da un calcolo sfruttando le colonne (co2_emissions e forested_area) prendendo solo i dati non "NULL" (non vuoti).

```
CREATE VIEW correlation AS (

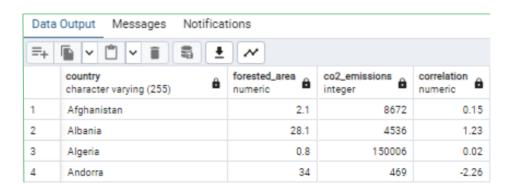
SELECT country, forested_area, co2_emissions,

ROUND((co2_emissions - AVG(co2_emissions) OVER()) / (STDDEV(co2_emissions) OVER() *

(forested_area - AVG(forested_area) OVER()) / (STDDEV(forested_area) OVER())), 2) AS correlation

FROM data_2023
WHERE co2_emissions IS NOT NULL OR forested_area IS NOT NULL

**Ontenuto VIEW "correlation":
```



• La seconda query, è una vista denominata "pearson" contenente i paesi, la percentuale di area forestale, le emissioni da "data_2023" e "correlation" dalla precedente vista "correlation", unendola tramite la colonna "country", infine è stata aggiunta una colonna "Interpretazione_Pearson_correlation", che in base al valore di "correlation" inserisce una definizione in caratteri.

```
474 */
     CREATE VIEW pearson AS
476
           (SELECT d.country, d.forested area, d.co2 emissions, c.correlation,
477
               CASE
                    WHEN c.correlation > 0.8 THEN 'Forte correlazione positiva'
478
479
                    WHEN c.correlation < -0.8 THEN 'Forte correlazione negativa'
488
                    FLSE 'Correlazione debole o inesistente'
481
               END AS Interpretazione Pearson correlation
                                                                                                 Contenuto VIEW "pearson":
482
          FROM data_2023 d, correlation c
483
          WHERE d.country = c.country);
                                                           Data Output Messages
                                                                                 Notifications
484
                                                                                                                                 interpretazione pearson correlation
                                                                character varying (255)
                                                                                                   2.1
                                                                                                                             0.15 | Correlazione debole o inesistente
                                                                Afghanistan
                                                                Albania
                                                                                                  28.1
                                                                                                                             1.23 Forte correlazione positiva
                                                                                                   0.8
                                                                                                               150006
                                                                                                                            0.02 Correlazione debole o inesistente
                                                                Algeria
                                                                Andorra
                                                                                                                            -2.26 Forte correlazione negativa
                                                                Angola
                                                                                                                34693
                                                                                                                            -0.26 Correlazione debole o inesistente
                                                           Total rows: 188 of 188
                                                                                Query complete 00:00:00.173
```

• La terza è una CTE, chiamata "conteggi", è stata creata usufruendo dei dati nella colonna "Interpretazione_Pearson_correlation" dalla precedente vista "pearson", contenente la quantità totale di righe e la quantità di righe che corrispondono ad una determinata condizione.

Contenuto CTE "conteggi":



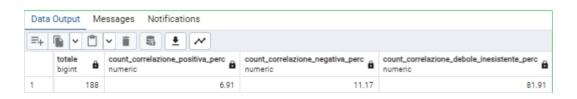


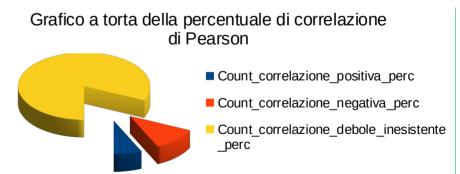
• Infine, nella quarta, sono stati utilizzati i risultati ottenuti dalla CTE "conteggi" per calcolare la suddivisione in percentuale degli elementi.

```
Totale,
ROUND(Count_correlazione_positiva * 100.0 / totale, 2) AS Count_correlazione_positiva_perc,
ROUND(Count_correlazione_negativa * 100.0 / totale, 2) AS Count_correlazione_negativa_perc,
ROUND(Count_correlazione_debole_inesistente * 100.0 / totale, 2) AS Count_correlazione_debole_inesistente_perc
FROM conteggi;

FROM conteggi;
```

Risultato:







CONSIDERAZIONI FINALI

In conlusione, questo progetto è finalizzato a fare pratica con il linguaggio SQL mediante la creazione di query per estrarre dati semplici o trovarne correlazioni sfruttando *file csv* contenenti dati provenienti da molti paesi; è stato interessante scoprire le differenze tra i vari paesi partendo dal numero totale della popolazione, confrontandone i dati relativi alla sanità o all'ecologia, vedendo i vari progressi ed evidenziando le differenze fra i paesi o di un singolo paese al variare del tempo.





LINK PROGETTO

All'interno di questo Drive sono disponibili i file csv opportunamente modificati per l'importazione e lo script SQL:

progetto sql - Google Drive



This work is licensed under a Creative Commons Attribution 4.0 International License.

